

Social Influence Learning for Recommendation Systems

论文笔记

申健强 2313119

2025 年 4 月 3 日

基本信息

- **发表刊物:** Proceedings of the 33rd ACM International Conference on Information and Knowledge Management (CIKM '24)
- **发表年份:** 2024
- **第一完成单位 (国内):** 澳门大学
- **作者:** Ximing Chen, Pui Ieng Lei, Yijun Sheng, Yanyan Liu, Zhiguo Gong
- **关键词 (中文):** 社交推荐; 社会影响; 生成模型; 图卷积网络
- **关键词 (英文):** Social Recommendation; Social Influence; Generative Models; Graph Convolutional Networks

2. 社会影响传播: 图神经网络中, 邻居层次越近并不必然带来越强影响, 应根据用户与各层邻居的行为一致性自适应加权。
3. 隐式社会影响探索: 通过用户—物品交互挖掘潜在弱连边, 补全社交图以缓解稀疏性, 但需避免用户表示塌陷。

具体情况如下图所示:




图 1: 三大挑战

论文内容

解决的问题 (如有实际应用场景请说明)

社交推荐系统利用用户社交关系来缓解用户—物品交互数据的冷启动和稀疏性问题, 但现有方法多将社交图作为静态辅助, 未能挖掘并优化隐藏的社会影响模式, 导致社交影响潜力未被充分利用。

三大挑战:

1. 社会影响多样性: 用户之间存在朋友、家人、同事等多种关系类型, 不同关系对行为的影响模式各异, 但缺乏关系标签, 难以区分影响来源。

解决问题的方法 (采用什么模型框架等)

一、整体架构概述

双路径图卷积模型框架主要由以下几部分构成:

1. **输入层:** 负责接收并预处理用户—物品交互数据和用户社交关系数据。
2. **双路径处理:** 包括
 - 二分图路径: 对用户—物品二分图进行多层图卷积;

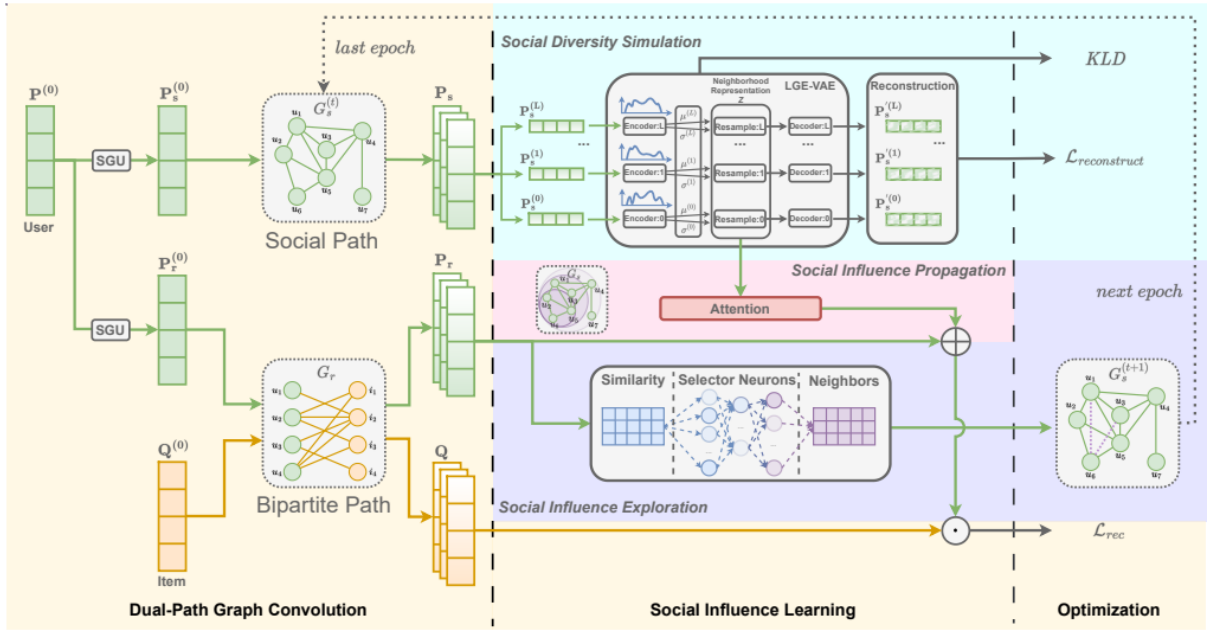


图 2: 模型框架

- 社会图路径：对用户社交图进行多层图卷积。
3. **双重部分掩码预处理**：在两条路径的每一层图卷积前，分别应用掩码矩阵筛选关键信息。
 4. **融合层**：将两条路径输出的用户表示进行拼接或加权融合，并通过全连接层映射到任务空间。
 5. **输出层**：根据具体任务（如评分预测或 Top-K 排序）生成最终结果，并计算相应损失进行优化。

二、输入层详细解释

1. 数据来源与组织

- **二分图数据**：从业务数据库获取用户对物品的购买、浏览、评分等操作记录，构建用户节点与物品节点，并以交互关系为边，边权可由交互次数或评分值决定。
- **社会图数据**：从社交平台获取用户好友或关注关系，构建用户节点，若存在社交关系则连边，边权可反映互动频率或亲疏程度。

2. 数据预处理

- **数据清洗**：剔除异常交互记录或孤立节点。
- **特征归一化**：如将评分 $[1, 5]$ 线性映射至 $[0, 1]$ ，以稳定后续训练。

三、双路径结构详细解释

1. 二分图路径

- **节点特征表示**：用户特征可包含年龄、性别、历史交互统计（平均消费、频次）；物品特征可包含类别、价格、品牌等。
- **图卷积操作**：每层更新

$$\mathbf{h}_u^{(l+1)} = \sigma \left(\sum_{i \in \mathcal{N}_r(u)} w_{ui} \mathbf{h}_i^{(l)} + b \right),$$

其中 $\mathcal{N}_r(u)$ 为与用户 u 相连的物品邻居集， w_{ui} 为边权， σ 为激活函数（如 ReLU）。

- **信息传递与聚合**：浅层聚合直接邻居信息，深层可获取多跳邻居特征，实现高阶交互表示。

2. 社会图路径

- **节点特征表示**：用户特征除基本属性外，还可加入社交中心性（度中心性、介数中心性）、社交群体特征等。

- 图卷积操作：每层更新

$$\mathbf{h}_u^{(l+1)} = \sigma\left(\sum_{v \in \mathcal{N}_s(u)} w_{uv} \mathbf{h}_v^{(l)} + b\right),$$

其中 $\mathcal{N}_s(u)$ 为社交邻居集， w_{uv} 表示社交关系强度。

- 信息传递与聚合：通过多层卷积获取多跳社交关系信息，形成用户的社交影响表示。

四、双重部分掩码预处理详细解释

1. 掩码原理

- 在二分图路径中，掩码矩阵 $\mathbf{M}_r^{(l)} \in \{0, 1\}^{|\mathcal{E}_r| \times |\mathcal{E}_r|}$ 控制每层边信息传递： $\mathbf{M}_r^{(l)}[u, i] = 1$ 时允许用户—物品交互信息流入第 l 层卷积，否则屏蔽。
- 在社会图路径中，掩码矩阵 $\mathbf{M}_s^{(l)} \in \{0, 1\}^{|\mathcal{E}_s| \times |\mathcal{E}_s|}$ 同理，用于筛选社交关系信息。

2. 预处理的作用

- 早期过滤无关或噪声边，减少冗余信息干扰。
- 控制模型复杂度，提升训练稳定性与泛化能力。

五、融合层详细解释

1. 融合策略

- 拼接融合：将二分图路径输出 \mathbf{h}_u^r 与社会图路径输出 \mathbf{h}_u^s 直接拼接， $\mathbf{h}_u = [\mathbf{h}_u^r \parallel \mathbf{h}_u^s]$ 。
- 加权融合： $\mathbf{h}_u = w_r \mathbf{h}_u^r + w_s \mathbf{h}_u^s$ ，其中 $w_r + w_s = 1$ ，权重可通过训练学习。

2. 融合后处理

- 融合向量经全连接层映射： $\mathbf{o}_u = \phi(\mathbf{W} \mathbf{h}_u + \mathbf{b})$ ， ϕ 为激活函数（如 Sigmoid、Softmax 等）。

六、输出层详细解释

1. 任务导向的输出

- 评分预测：输出实数 $\hat{r}_{u,i}$ ，采用回归全连接层。
- *Top-K* 推荐：输出得分向量 $\hat{\mathbf{r}}_u$ ，对物品按得分排序。
- 分类任务：输出类别概率 $\mathbf{p}_u = \text{Softmax}(\mathbf{o}_u)$ ，选择最大概率类别。

2. 损失函数与优化

- 回归任务：均方误差 $\text{MSE} = \frac{1}{N} \sum (\hat{r} - r)^2$ 。
- 排序任务：BPR 损失 $-\ln \sigma(\hat{r}_{u,i} - \hat{r}_{u,j})$ 。
- 分类任务：交叉熵损失 $-\sum y \ln p$ 。
- 采用 Adam 等优化器最小化联合损失，端到端更新所有参数。

最终将社交路径输出 P_s 与二分图输出 P_r 融合： $P_{\text{final}} = P_r + \sigma(P_s W_{\text{agg}})$ ，并以 BPR 损失和 VAE 重构损失联合优化。

训练过程解析

1. 输入与输出

- 输入：
 - 用户—物品交互矩阵 R ，反映用户对物品的购买、浏览、评分等交互行为。
 - 社交网络矩阵 S ，反映用户之间的显式社交关系（如好友、关注）。
 - 初始化嵌入 $P^{(0)}$ （用户）和 $Q^{(0)}$ （物品），作为模型的初始特征表示。
- 输出：
 - 最终用户嵌入 P_{final} 和物品嵌入 Q ，用于计算推荐分数。
 - 增强后的社交网络 \tilde{S} ，包含显式与隐式采样得到的边，提供更丰富的社交信息。

2. 训练过程解析

结合算法伪代码，训练流程如下：

1. **外层循环 (Epoch)**：对所有数据多轮遍历，不断优化模型。
2. **内层循环 (Batch)**：将数据分批次处理，节省内存并加速训练。
3. **自门控单元预处理**：

$$P_s^{(0)}, P_r^{(0)} = P^{(0)} \odot \sigma(P^{(0)} W_g^{\text{path}} + b_g^{\text{path}}),$$

控制二分图与社交图路径的信息流量。

4. **多层图卷积** ($l = 0, \dots, L - 1$):

$$P_r^{(l+1)} = D_{user}^{-1} R Q^{(l)},$$

$$Q^{(l+1)} = D_{item}^{-1} R^\top P_r^{(l)},$$

$$P_s^{(l+1)} = D_s^{-1} S P_s^{(l)}.$$

5. **社会影响多样性模拟 (LGE-VAE)**:

$$(\mu^{(l)}, \sigma^{(l)}) = \text{MLP}(P_s^{(l)}),$$

$$Z_s^{(l)} = \mu^{(l)} + \sigma^{(l)} \odot \epsilon, \epsilon \sim \mathcal{N}(0, I).$$

6. **注意力分数计算**:

$$\alpha_l = \frac{\exp(a^\top W_{\text{att}} Z_s^{(l)})}{\sum_j \exp(a^\top W_{\text{att}} Z_s^{(j)})}.$$

7. **重构与推荐损失**:

$$L_{\text{VAE}} = -E_{q_\phi} [\log p_\psi(P_s | Z_s)] + \beta \text{KL}(q_\phi \| p),$$

$$L_{\text{rec}} = \sum_{i \in I(u), j \notin I(u)} -\ln \sigma(\hat{r}_{u,i} - \hat{r}_{u,j}).$$

8. **社交影响传播**:

$$\tilde{P}_s = \sum_{l=0}^L \alpha_l Z_s^{(l)}.$$

9. **融合生成最终嵌入**:

$$P_{\text{final}} = P_r + \sigma(\tilde{P}_s W_{\text{agg}}).$$

10. **隐式社交探索 (Dual Sampling)**: Gumbel 采样 + Bernoulli 采样更新 \tilde{S} 。

仍旧存在的问题（注明论文中说明的问题或自己认为存在的问题）

- 1 社会网络的稀疏性：论文指出，当社会网络较为稀疏时，基于图的一般推荐模型的性能甚至优于基于图的社交推荐模型。这表明在不同的社会网络密度下，模型的适用性和性能可能会有所不同，未来需要进一步研究如何在不同密度的社会网络中优化模型。
- 2 隐式社会图的相似性分析：虽然论文展示了隐式社会图的相似性分析结果，但指出不同类型的邻居（显性邻居和隐式邻居）的相似性较低，反映了社会影响的多样性。未来工作可以进一步探讨如何更好地利用这些隐式社会关系来改进推荐系统。

实验内容

实验采用的数据集

使用 LastFM、Flickr、Yelp 三个隐式反馈数据集，分别包含用户—物品交互和社交关系，其中社交图稀疏度各异（见表 1）。

表 1: 数据集统计信息

数据集	用户数	物品数	交互数	关系数
LastFM	1,892	17,632	92,834	25,434
Flickr	8,358	82,120	314,809	187,273
Yelp	17,237	38,342	204,448	143,765

实验是否涉及实际应用场景

仅基于公开学术基准，无特定线上应用部署。

1

实验采用的对比方法

为了验证模型的优越性，作者团队将 EIISRS 与一些代表性模型进行比较，如下所示：

BPR, SBPR, CDAE, Multi-VAE, NGCF, LightGCN, DiffNet++, ESRF

¹由于本文的作者团队并未开源他们的代码，导致本人在进行复现尝试时遇见了一些困难，在这里目前没有办法能够对实验的一些细节进行详细的描述和讲解，在此处只能对论文中提到的数据进行讲解了

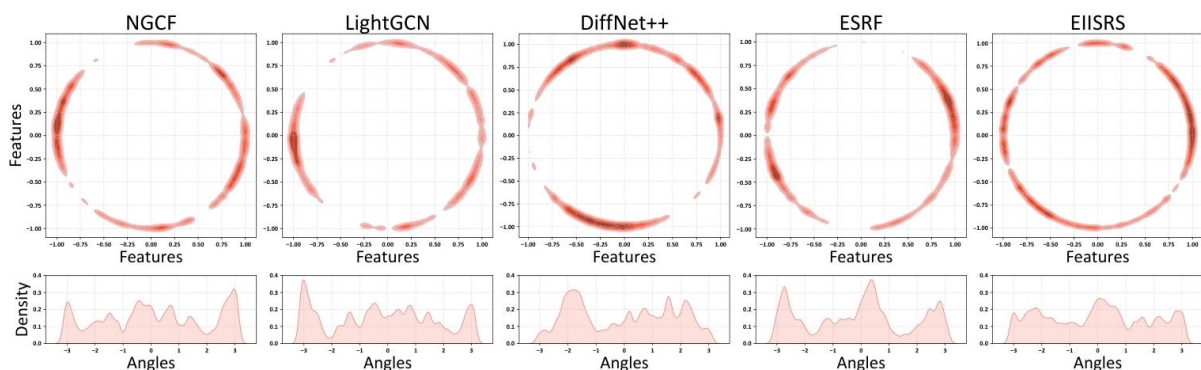


图 3: EIISRS 在用户信息捕捉 zho

实验衡量指标

对于推荐评估，作者团队采用了四项广泛使用的任务指标：基于分类的指标精确率 Precision@k、Recall@k、F1@k，以及基于排名的指标 NDCG@k。对所有项目进行项目排名，而不是对抽样项目集进行排名，以确保评估是无偏且稳健的。改进超过 1% 被认为是有意义的

实验结果

各个模型的表现对比如下图4所示

消融实验

为了研究模型中每个组件的有效性，作者团队通过删除 EIISRS 的某些部分来创建四个变体，并将它们与我们原始的完整模型（即 EIISRS）进行比较。SIP、SID 和 SIE 分别是指从模型中删除了 Social Influence Propagation、Social Influence Diversity 和 Social Influence Exploration 的变体。Vanilla 指的是 backbone 模型，它删除了所有三个组件。于是作者团队得到以下结果

从图 5 中，可以很容易地观察到，在移除任何组件后，性能会变得更差。最显着的性能下降发生在 SID 中。由上可知，社会影响力多样性的模拟非常适合解决社交网络上社交推荐的稀疏性和不一致性问题。同时，通过与 Vanilla 的比较，可以得出结论，每个组件都对模型有贡献，并且组件之间的合作很重要。

案例解析

用户表征崩溃被定义为用户被困在可观察项目中，但忽视了不同兴趣的巨大潜力的现象。在 EIISRS 设计下，两个新颖的组成部分（即社会多样性模拟、双重抽样过程）可以有效缓解这个问题。作者团队在 LastFM 上通过可视化来分析用户表示折叠。我们使用 t-SNE 将不同模型生成的最终用户表示映射到二维归一化向量，并使用高斯核密度估计 (KDE) 绘制它们。上图显示了用户表示的分布，下图是根据他们的角度绘制的（即 $\arctan2(y, x)$ ）。请注意，NGCF 和 LightGCN 是通用推荐模型，而 DiffNet++、ESRF 和 EIISRS 是社交推荐模型。

根据图 3，可以观察到，与其他模型相比，EIISRS 在顶部产生了更圆润的圆图，在底部图形上产生了更平滑的曲线峰值。它表明，当涉及到稀疏的用户-项目交互图或社交图时，EIISRS 可以很好地缓解用户表示折叠问题，能够更为精准的捕捉用户的特征信息。

实验说明所提出方法的优点

- 在三数据集上均显著优于所有基线，次优模型提升 1.8%–9.1%。
- 消融实验表明，移除任一组件均导致性能下降，尤其是多样性模拟。
- 注意力聚合优于平均/最大/拼接等方法，表明层次注意力在社交图中有效。
- 超参数敏感性实验显示，模型对候选邻居数和 Gumbel 温度鲁棒。

Model	LastFM				Flickr				Yelp			
	P@10	R@10	F1@10	N@10	P@10	R@10	F1@10	N@10	P@10	R@10	F1@10	N@10
BPR	0.1157	0.1180	0.1168	0.1452	0.0019	0.0020	0.0019	0.0021	0.0019	0.0071	0.0030	0.0045
SBPR	0.1559	0.1564	0.1561	0.2019	0.0018	0.0018	0.0013	0.0024	0.0032	0.0121	0.0051	0.0074
CDAE	0.0364	0.0755	0.0491	0.0682	0.0013	0.0034	0.0019	0.0026	0.0013	0.0110	0.0023	0.0054
Multi-VAE	0.0950	0.1825	0.1250	0.1607	0.0015	0.0044	0.0022	0.0031	0.0028	0.0232	0.0050	0.0118
NGCF	0.1662	0.1708	0.1685	0.2079	0.0026	0.0034	0.0030	0.0034	0.0041	0.0162	0.0066	0.0098
LightGCN	0.1631	0.1676	0.1653	0.2137	<u>0.0033</u>	0.0039	0.0036	0.0044	<u>0.0061</u>	<u>0.0238</u>	<u>0.0097</u>	<u>0.0149</u>
DiffNet++	0.1722	0.1751	0.1736	0.2069	0.0030	0.0032	0.0031	0.0038	0.0049	0.0179	0.0076	0.0111
ESRF	<u>0.1913</u>	<u>0.1968</u>	<u>0.1940</u>	<u>0.2465</u>	<u>0.0033</u>	<u>0.0046</u>	<u>0.0039</u>	<u>0.0047</u>	0.0055	0.0209	0.0088	0.0130
EIISRS	0.1953	0.2004	0.1978	0.2532	0.0036	0.0047	0.0041	0.0051	0.0066	0.0244	0.0103	0.0153
Improv.	2.1%	1.8%	2.0%	2.7%	9.1%	2.2%	5.1%	7.8%	8.2%	2.5%	6.2%	2.7%

图 4: 不同种模型的表现对比




图 5: 消融实验结果

论文仍然可以改进的地方是什么

- 自动调节超参数以减少人工调参成本。
- 引入时序或上下文信息提升隐式邻居采样质量。
- 优化模型结构或训练策略以适应超大规模图。

- 案例研究证明 EIISRS 能缓解用户表示塌陷并挖掘有意义的隐式邻居。

思考内容

论文的主要优点是什么

- 系统地针对显式与隐式社会影响三大挑战提出解决方案。

论文详细分析了社会推荐系统中的显性影响多样性、显性影响传播和隐性社会影响探索三个问题，并针对这些问题提出了相应的解决方案。

- 提出了一种基于 GCN 的双塔架构:该模型结合了层间图增强变分自编码器 (LGE-VAE)、层间图注意力网络和双重采样过程，首次将这些方法用于社会网络解耦。
- 创新地将 VAE、图注意力和双采样结合，端到端联合优化。
- 在不同稀疏度场景下表现稳健，对冷启动和稀疏性具有显著改善。